



Universidade de Pernambuco  
Campus Caruaru  
Bacharelado em Sistemas de Informação

**Identificação Automatizada da Fêmea do  
*Aedes aegypti* com Redes Neurais  
Convolucionais: Uma Abordagem para o  
Controle Epidemiológico da Dengue**

**Trabalho de Graduação  
Sistemas de Informação**

**Ariel Nunes Braz Gomes**  
**Orientadora: Prof. Erika Medeiro**

**Ariel Nunes Braz Gomes**

**Identificação Automatizada da Fêmea  
do *Aedes aegypti* com Redes Neurais  
Convolucionais: Uma Abordagem para  
o Controle Epidemiológico da Dengue**

Monografia apresentada como requisito  
parcial para obtenção do diploma de Bacharel em  
Sistemas de Informação pela Universidade de  
Pernambuco – UPE, Campus Caruaru.

Caruaru, Dezembro e 2024.

*Dedico esse trabalho de conclusão de curso primeiramente a Deus, aos meus pais, meus avós e todas as pessoas que acreditaram em mim e me apoiaram para a realização do próprio.*

# **Agradecimentos**

Agradeço primeiramente a minha orientadora Erika Carlos Medeiros e aos meus amigos que me ajudaram nesse trabalho de conclusão de curso: Daniel Victor Da Silva Barros, Marco Antonio de Medeiros Levy, João Victor Mendes de Lira, Anna Beatriz Silva e Guilherme Silveira Coutinho.

# Resumo

A dengue, uma doença viral de grande impacto global, é transmitida pelo mosquito *Aedes aegypti*, especialmente em regiões tropicais e subtropicais onde este encontra condições ideais para reprodução. A fêmea dessa espécie, responsável pela transmissão, é um alvo crucial para o controle eficaz da disseminação da doença. Contudo, diferenciá-la de outras espécies e gêneros de mosquitos é um desafio devido às semelhanças morfológicas, sendo necessária uma precisão elevada para evitar erros nas estratégias de controle. Neste contexto, este trabalho propõe uma abordagem automatizada para identificar a fêmea do *Aedes aegypti* utilizando redes neurais convolucionais com técnicas de aprendizado de máquina, aplicadas a uma base de dados de imagens de alta resolução coletadas por microscopia digital. O objetivo desta pesquisa é implementar um modelo CNN robusto e preciso, capaz de identificar a fêmea do *Aedes aegypti* e, assim, contribuir para o monitoramento e controle dos surtos de dengue. A metodologia adotada inclui o pré-processamento das imagens com técnicas de normalização e *data augmentation*, o que permite ao modelo extrair características relevantes e melhorar a acurácia. Foram configurados e testados dois modelos de CNN: uma rede baseada na *MobileNetV2* e outra na *VGG16*, ambas adaptadas para classificar entre as classes macho e fêmea. Esses modelos foram avaliados por meio de métricas como acurácia, precisão, *recall*, *F1-score* e curva *ROC*, assegurando uma análise abrangente de sua eficácia. Os resultados indicam que o modelo *MobileNetV2* superou o *VGG16*, alcançando uma acurácia final de 93% e resultados superiores nas demais métricas de avaliação. Esse desempenho destaca a robustez do modelo *MobileNetV2* na classificação, consolidando-o como uma ferramenta promissora para a identificação automática do vetor de dengue em programas de monitoramento. Conclui-se que o uso de CNNs, com a arquitetura *MobileNetV2*, oferece uma contribuição valiosa para os sistemas de vigilância e controle epidemiológico, sendo uma solução para a prevenção e redução da dengue.

**Palavras-chave:** *Aedes aegypti*, CNN, identificação automática, dengue, aprendizado de máquina.

# Abstract

Dengue, a viral disease with significant global impact, is transmitted by the *Aedes aegypti* mosquito, particularly in tropical and subtropical regions where it finds ideal breeding conditions. The female of this species, responsible for transmission, is crucial for effective disease control. However, distinguishing it from other mosquito species presents a challenge due to morphological similarities, demanding high precision to avoid errors in control strategies. This study proposes an automated approach for identifying the female *Aedes aegypti* using convolutional neural networks and machine learning techniques applied to a high-resolution image database obtained through digital microscopy. The objective of this research is to implement a robust and accurate CNN model capable of identifying the female *Aedes aegypti*, thus supporting dengue outbreak monitoring and control. The methodology includes image preprocessing through normalization and data augmentation techniques, enabling the model to extract relevant features and improve accuracy. Two CNN models were configured and tested: one based on MobileNetV2 and another on VGG16, both adapted to classify between male and female classes. These models were evaluated using metrics such as accuracy, precision, recall, F1-score, and ROC curve, ensuring a comprehensive analysis of their effectiveness. Results indicate that the MobileNetV2 model outperformed VGG16, achieving a final accuracy of 93% and superior results across other evaluation metrics. This performance underscores the robustness of MobileNetV2 for classification, positioning it as a promising tool for the automated identification of dengue vectors in monitoring programs. In conclusion, the use of CNNs, particularly with the MobileNetV2 architecture, offers a valuable contribution to epidemiological surveillance and control systems, providing a solution for dengue prevention and reduction.

**Keywords:** *Aedes aegypti*, CNN, automatic identification, dengue, machine learning.

# **Lista de Figuras**

Figura 1 - Distribuição das classes .....	17
Figura 2 – Arquitetura do CNN .....	20
Figura 3 – Arquitetura do VGG16 .....	21
Figura 4 – Matriz de Confusão do VGG16.....	26
Figura 5 – Gráfico de Acurácia e Perda do modelo VGG16.....	27
Figura 6 – Curva Roc do modelo VGG16.....	27
Figura 7 – Matriz de confusão do CNN .....	28
Figura 8 – Gráficos de Acurácia e Perda do modelo CNN .....	29
Figura 9 - Curva ROC do modelo CNN .....	29

# **Lista de Tabelas**

Tabela 1 - Avaliação das métricas ..... 24

# **Lista de Siglas**

TCC – Trabalho de Conclusão de Curso

IA – Inteligência Artificial

CRISP-DM - *Cross Industry Standard Process for Data Mining.*

CNN – Modelo de rede neural convolucional.

VGG16 – Modelo de rede neural convolucional profunda.

AUC - *Area under the curve.*

Curva Roc - *Receiver operating characteristic.*

# **Sumário**

<b>Resumo</b>	<b>viii</b>
<b>Abstract</b>	<b>ix</b>
<b>Lista de Figuras</b>	<b>x</b>
<b>Lista de Tabelas</b>	<b>xi</b>
<b>Lista de Siglas</b>	<b>xii</b>
<b>Sumário</b>	<b>xiii</b>
<b>Capítulo 1</b>	<b>10</b>
<b>Introdução</b>	<b>10</b>
1.1    Objetivo Geral e objetivos específicos	12
<b>Capítulo 2</b>	<b>14</b>
<b>Trabalhos relacionados</b>	<b>14</b>
<b>Capítulo 3</b>	<b>16</b>
<b>Metodologia</b>	<b>16</b>
3.1.    Entendimento do negócio	16
3.2 Entendimento dos dados	17
3.3 Preparação dos dados	18
3.4 Modelagem	18
3.4 Avaliação	22
<b>Capítulo 4</b>	<b>24</b>
<b>Resultados</b>	<b>24</b>

4.1 Desempenho do modelo <i>VGG16</i>	25
4.2 Desempenho do Modelo <i>CNN</i>	28
4.3 Análise detalhada dos modelos	30
<b>Capítulo 5</b>	<b>32</b>
<b>Considerações Finais</b>	<b>32</b>
<b>Referências</b>	<b>34</b>

# Capítulo 1

## Introdução

A dengue é uma doença viral transmitida principalmente pelo mosquito *Aedes aegypti*, que tem se tornado um grave problema de saúde pública no Brasil e em diversas regiões tropicais e subtropicais. Em 2024, o país registrou mais de 2 milhões de casos de dengue, o maior número já documentado desde o início dos registros em 2000, com mais de 680 mortes confirmadas até março desse ano (G1, 2024). Esse aumento expressivo nos casos ressalta a necessidade urgente de estratégias eficazes para o controle e prevenção da doença.

A identificação precisa do mosquito *Aedes aegypti*, especialmente das fêmeas, que são as responsáveis pela transmissão do vírus, é fundamental para o desenvolvimento de medidas de controle direcionadas. A detecção precoce e precisa desses vetores permite intervenções mais eficazes, como a eliminação de focos de reprodução e a aplicação de inseticidas de forma mais estratégica. Além disso, a identificação correta auxilia na implementação de programas de vigilância entomológica, essenciais para monitorar a densidade populacional do mosquito e prever possíveis surtos (Ministério da Saúde, 2022).

A dificuldade na identificação das fêmeas do *Aedes aegypti* reside na semelhança morfológica com outras espécies de mosquitos, o que pode levar a diagnósticos equivocados e, consequentemente, a medidas de controle ineficazes. Portanto, aprimorar as técnicas de identificação é crucial para a eficácia das ações de saúde pública. A utilização de métodos precisos de identificação contribui para a alocação adequada de recursos e para a redução da incidência da dengue, minimizando o impacto socioeconômico da doença (Fiocruz, 2024).

A motivação para enfrentar o problema da identificação e controle do *Aedes aegypti* está diretamente ligada aos impactos devastadores que a dengue causa na saúde pública e na economia. O aumento de casos nos últimos anos, com registros históricos de incidência e mortalidade, reforça a necessidade de estratégias eficazes

para a identificação precisa do mosquito, especialmente das fêmeas, responsáveis pela transmissão da doença. O controle adequado desse vetor pode reduzir significativamente a incidência de dengue e outras arboviroses, como chikungunya e zika, aliviando a pressão sobre o sistema de saúde, que enfrenta desafios crescentes com a hospitalização e tratamento de casos graves. Além disso, a identificação correta dos mosquitos permite que recursos, como inseticidas e equipes de controle, sejam direcionados de maneira mais estratégica, gerando maior impacto com menor custo operacional. Esse foco direcionado é essencial para uma abordagem sustentável e eficaz no combate ao *Aedes aegypti*, com benefícios claros para a saúde coletiva e a economia.

A aplicação de redes neurais, especialmente as convolucionais (CNNs), na identificação do mosquito *Aedes aegypti* é motivada por avanços recentes em aprendizado profundo, que mostraram eficácia em classificações complexas de imagens entomológicas. Estudos como o de Cordeiro Júnior (2020) destacam que o uso de CNNs para a identificação de mosquitos alcançou altas taxas de acurácia, mas esses modelos ainda enfrentam limitações, como a necessidade de aprimorar a identificação em diferentes ângulos e condições de iluminação(JÚNIOR, 2022).

Outros trabalhos, como o de Garcia, evidenciam o potencial das CNNs para distinguir ovos e larvas de diferentes espécies de mosquitos, sugerindo que a mesma técnica poderia ser aplicada aos espécimes adultos para melhorar o controle epidemiológico(GARCIA, 2019). Embora esses estudos indiquem progresso significativo, ainda há espaço para soluções que aumentem a robustez e a precisão das classificações automáticas, especialmente no contexto da identificação do vetor fêmea. Dessa forma, este trabalho visa contribuir para o campo com um modelo que possa ser facilmente aplicado em imagens de microscópio, oferecendo uma alternativa prática e eficiente para o controle de arboviroses.

Diante desse contexto, a pergunta central que norteia esta pesquisa é: É possível desenvolver modelos de aprendizado de máquina capazes de identificar o mosquito fêmea da espécie *Aedes Aegypti* transmissora da dengue com base em imagens de mosquitos *Aedes Aegypti* machos e fêmeas?

## 1.1 Objetivo Geral e objetivos específicos

O objetivo geral desta pesquisa é desenvolver modelos de aprendizado de máquina capazes de identificação a fêmea do mosquito aedes aegypti transmissora da dengue com base em imagens de mosquitos aedes aegypti machos e fêmeas.

- Para realizar o pré-processamento das imagens, é utilizada a mesma base de dados empregada na dissertação de Geraldo Pires Cordeiro Júnior(JÚNIOR, 2022), que contém uma vasta coleção de imagens de mosquitos das espécies Aedes aegypti, Aedes albopictus e Culex quinquefasciatus. As imagens passam por técnicas de normalização, redimensionamento e data augmentation, visando adequá-las para o treinamento de uma CNN. Este processo é essencial para otimizar a extração de características e, consequentemente, melhorar a acurácia do modelo de classificação dos mosquitos;
- Treinar CNNs utilizando as imagens pré-processadas na etapa anterior. Este objetivo visa a identificação a fêmea do mosquito aedes aegypti transmissora da dengue com base em imagens de mosquitos aedes aegypti machos e fêmeas;
- Identificar e analisar as arquiteturas de CNN com base em métricas de desempenho, tais como acurácia (MONICO et al., 2009), precisão, recall, F1-Score, matriz de confusão (BEAUXIS-AUSSALET; HARDMAN, 2014) e Receiver Operating Characteristic Curve (Curva ROC) (FAN; UPADHYE; WORSTER, 2006). Isso permitirá uma compreensão aprofundada da eficácia de cada modelo;
- Escolher o modelo que apresentar as métricas mais elevadas de desempenho como o modelo final para a identificação a fêmea do mosquito aedes aegypti transmissora da dengue com base em imagens de mosquitos aedes aegypti machos e fêmeas;
- Identificar e analisar os modelos de aprendizado de máquina com base em métricas de desempenho, incluindo acurácia (MONICO et al., 2009), precisão (MARIANO, 2021), recall (TORGO; RIBEIRO, 2009), F1-Score (ZHANG;

WANG; ZHAO, 2015), matriz de confusão (PADMANABHAN, 2019) e Receiver Operating Characteristic curve (Curva ROC) (NAKAS, 2023);

Este trabalho está estruturado em cinco capítulos, começando pelo presente capítulo introdutório, que apresenta o contexto, motivação, pergunta de pesquisa e objetivos. O segundo capítulo abordará os trabalhos relacionados, apresentando pesquisas recentes na área de aprendizagem de máquina relacionadas a identificação a fêmea do mosquito *aedes aegypti* transmissora da dengue com base em imagens de mosquitos *aedes aegypti* machos e fêmeas. O terceiro capítulo descreverá a metodologia adotada, detalhando as etapas do pré-processamento de dados, treinamento dos modelos, além da avaliação de desempenho. O quarto capítulo apresentará os resultados obtidos e a análise dos modelos, enquanto o quinto e último capítulo consolidará as conclusões do estudo, destacando contribuições, limitações e sugestões para pesquisas futuras.

No próximo capítulo, será apresentado o capítulo de trabalhos relacionados, fornecendo uma base sólida para o entendimento das abordagens existentes e lacunas a serem exploradas.

# Capítulo 2

## Trabalhos relacionados

Neste capítulo, serão apresentadas pesquisas e estudos relevantes que fundamentam e contextualizam o presente trabalho, oferecendo uma visão abrangente do estado da arte na área de estudo. Serão explorados conceitos-chave, metodologias e resultados de pesquisas anteriores, que servem como base teórica e prática para o desenvolvimento deste projeto. Essa revisão de literatura visa identificar as principais contribuições, lacunas e desafios enfrentados por outros pesquisadores, destacando como os métodos e abordagens escolhidos se relacionam com o objetivo desta pesquisa.

A pesquisa de Dal Castel contribui significativamente ao implementar um sistema embarcado que permite a classificação de mosquitos *Aedes aegypti* diretamente em dispositivos de borda, utilizando CNNs. Essa abordagem reduz a necessidade de transferir dados para um servidor central, aumentando a eficiência e escalabilidade do monitoramento. No entanto, o estudo limita-se ao uso do microcontrolador *ESP32*, o que pode restringir o desempenho em ambientes com alta densidade de mosquitos e não explora completamente o potencial de processamento em dispositivos mais avançados (CASTEL, 2023). Motta foca na otimização da classificação morfológica de diferentes espécies de *Aedes* e *Culex*, utilizando um conjunto de imagens variado e técnicas de ajuste de hiperparâmetros em CNNs para reduzir erros. Esse autor demonstra a eficácia de ajustes finos de parâmetros na precisão do modelo, mas não aborda a viabilidade de uso em tempo real ou a adaptação a ambientes com iluminação e ângulos variáveis, o que são desafios comuns em campo (MOTTA, 2019).

A dissertação de Cordeiro Júnior explora redes como *VGG16*, *ResNet50* e *EfficientNetB0* para o reconhecimento de espécies de mosquitos transmissores de arboviroses, destacando a capacidade dessas arquiteturas em capturar características discriminativas. O estudo apresenta uma análise abrangente sobre a generalização e precisão dessas redes, mas identifica como limitação a necessidade

de maior poder computacional para treinar redes mais complexas, o que pode ser uma barreira para a implementação em sistemas com restrições de *hardware*(JÚNIOR, 2022). Mittelmann e Soares desenvolvem uma abordagem preditiva para a incidência de casos de dengue em Guarulhos, usando redes neurais que incorporam variáveis climáticas. A contribuição desse trabalho reside na integração de fatores ambientais que influenciam a transmissão da doença, permitindo um planejamento mais eficaz de ações preventivas. No entanto, o modelo é sensível a flutuações de dados climáticos e depende da disponibilidade de dados históricos completos, o que pode limitar sua aplicabilidade em áreas com registros insuficientes(MITTELMANN; APPLICADA; 2017, [s.d.]).

O estudo de Lima apresenta contribuições importantes para a identificação de espécies de culicídeos com base na morfometria das asas. Utilizando inteligência artificial, o autor desenvolveu um modelo automatizado que realiza a segmentação de asas e a extração de pontos anatômicos, aplicando a distância de *Mahalanobis* para classificar espécimes com base em similaridades morfométricas. A principal contribuição reside na combinação da morfometria geométrica com técnicas de aprendizado de máquina, especificamente um algoritmo *Random Forest*, que demonstrou precisão na identificação de padrões das veias das asas. No entanto, uma das lacunas mencionadas é a limitação de espécies no banco de dados, restringindo a abrangência do modelo. Além disso, o estudo sugere que melhorias poderiam ser alcançadas com a inclusão de mais espécies e a aplicação de novos métodos de detecção automática de pontos anatômicos, o que ampliaria a aplicabilidade do modelo em ambientes de campo e com diferentes espécies(VINICIO RODRIGUES DE LIMA, 2023).

Cada uma dessas pesquisas contribui com avanços relevantes na identificação e monitoramento de mosquitos vetores e na previsão de epidemias, mas enfrenta limitações quanto à escalabilidade, adaptabilidade em diferentes ambientes e viabilidade para uso em dispositivos com restrições de recursos. Esses desafios destacam a necessidade de soluções mais flexíveis e eficientes, que este trabalho busca abordar ao utilizar uma abordagem otimizada para a identificação do *Aedes aegypti*.

# Capítulo 3

## Metodologia

Nesta pesquisa, adota-se o Processo Padrão para Mineração de Dados Cruzada do Setor, *Cross Industry Standard Process for Data Mining* (CRISP-DM), como estrutura metodológica. O CRISP-DM é amplamente utilizado para guiar o desenvolvimento de projetos de mineração de dados e aprendizado de máquina, dividindo-se em seis fases principais que englobam desde o entendimento do problema até a implementação e avaliação do modelo desenvolvido. A aplicação dessa metodologia permitirá a construção e avaliação de modelos de aprendizado de máquina com o objetivo de antecipar a identificação da fêmea do mosquito *Aedes aegypti*, vetor da dengue, utilizando um conjunto de dados de imagens contendo exemplares machos e fêmeas do referido mosquito.

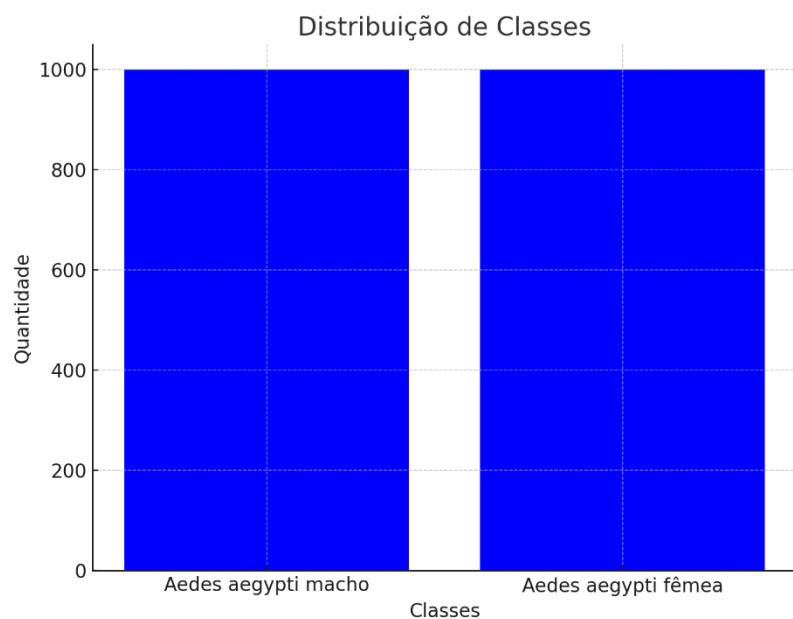
### 3.1. Entendimento do negócio

É fundamental para o desenvolvimento desta pesquisa, foi embasado por uma revisão da literatura apresentada no Capítulo 2, com foco em identificar os principais avanços, desafios e oportunidades no uso de modelos de aprendizado de máquina para a antecipação da identificação da fêmea do *Aedes aegypti*, vetor primário da dengue. A revisão abordou os impactos da IA na área, explorando o estado da arte e as tecnologias emergentes aplicadas à identificação de vetores de doenças. Foram levantadas lacunas significativas na área, evidenciando a necessidade de soluções mais precisas e automatizadas que suportem o controle epidemiológico, reduzindo a transmissão de arboviroses. Com isso, a pesquisa busca preencher essas lacunas ao desenvolver modelos que aprimorem a acurácia e a eficiência na identificação dos vetores, contribuindo de forma direta para o controle do *Aedes aegypti* e, consequentemente, para a redução dos impactos da dengue.

## 3.2 Entendimento dos dados

O conjunto de dados utilizado neste estudo é composto por 2000 registros de imagens da espécie *Aedes aegypti*, mosquito responsável pela transmissão da dengue. A coleção de dados foi organizada de maneira balanceada, sendo composta por 1000 imagens de exemplares machos e 1000 imagens de exemplares fêmeas do mosquito *Aedes aegypti*. Esse equilíbrio entre as duas classes é fundamental para garantir a precisão e a imparcialidade do modelo de aprendizado de máquina que será desenvolvido. A Figura 1 ilustra essa distribuição de classes no conjunto de dados, evidenciando a paridade entre as amostras de machos e fêmeas, o que minimiza o risco de vieses no treinamento e proporciona uma base sólida para a tarefa de classificação. Os registros de imagens de mosquitos foram coletados no Instituto Aggeu Magalhães, utilizando um microscópio digital modelo HT-60S com resolução de 5 MP. Para garantir um posicionamento adequado durante a captura das imagens, os espécimes foram manipulados com pinças de precisão e posicionados em uma base quadriculada de papel ofício fixada na base do microscópio. O processo de captura foi realizado com o objetivo de obter diferentes ângulos dos mosquitos, visando uma maior diversidade na base de dados.(JÚNIOR, 2022)

Figura 1 - Distribuição das classes



Fonte: Própria do Autor

### 3.3 Preparação dos dados

A preparação dos dados para o modelo incluiu o redimensionamento de todas as imagens para 255x255 pixels, a fim de garantir uma entrada uniforme para a o modelo CNN e para o modelo VGG16. Para o conjunto de treino, foram aplicadas técnicas de aumento de dados (*Data Augmentation*) com o objetivo de aumentar a diversidade das amostras e reduzir o risco de enviesamento (*overfitting*). Esse processo incluiu a normalização dos valores dos pixels para o intervalo 0 e 1, rotações aleatórias de até 40 graus, deslocamentos horizontais e verticais de até 20% da dimensão da imagem, cisalhamento, zoom e inversão horizontal. O conjunto de validação e o conjunto de teste passaram apenas por uma normalização dos pixels para o intervalo 0 e 1, sem outras transformações, assegurando a consistência das avaliações. As imagens foram divididas em lotes de 32 amostras e organizadas de forma categórica para o modelo distinguir entre duas classes. O treinamento foi estruturado para utilizar um modelo sequencial com camadas convolucionais e de polimento, seguido de camadas densas para extração de características, e uma camada de saída *softmax* para a classificação das imagens em duas categorias: machos e fêmeas do *Aedes aegypti*.

### 3.4 Modelagem

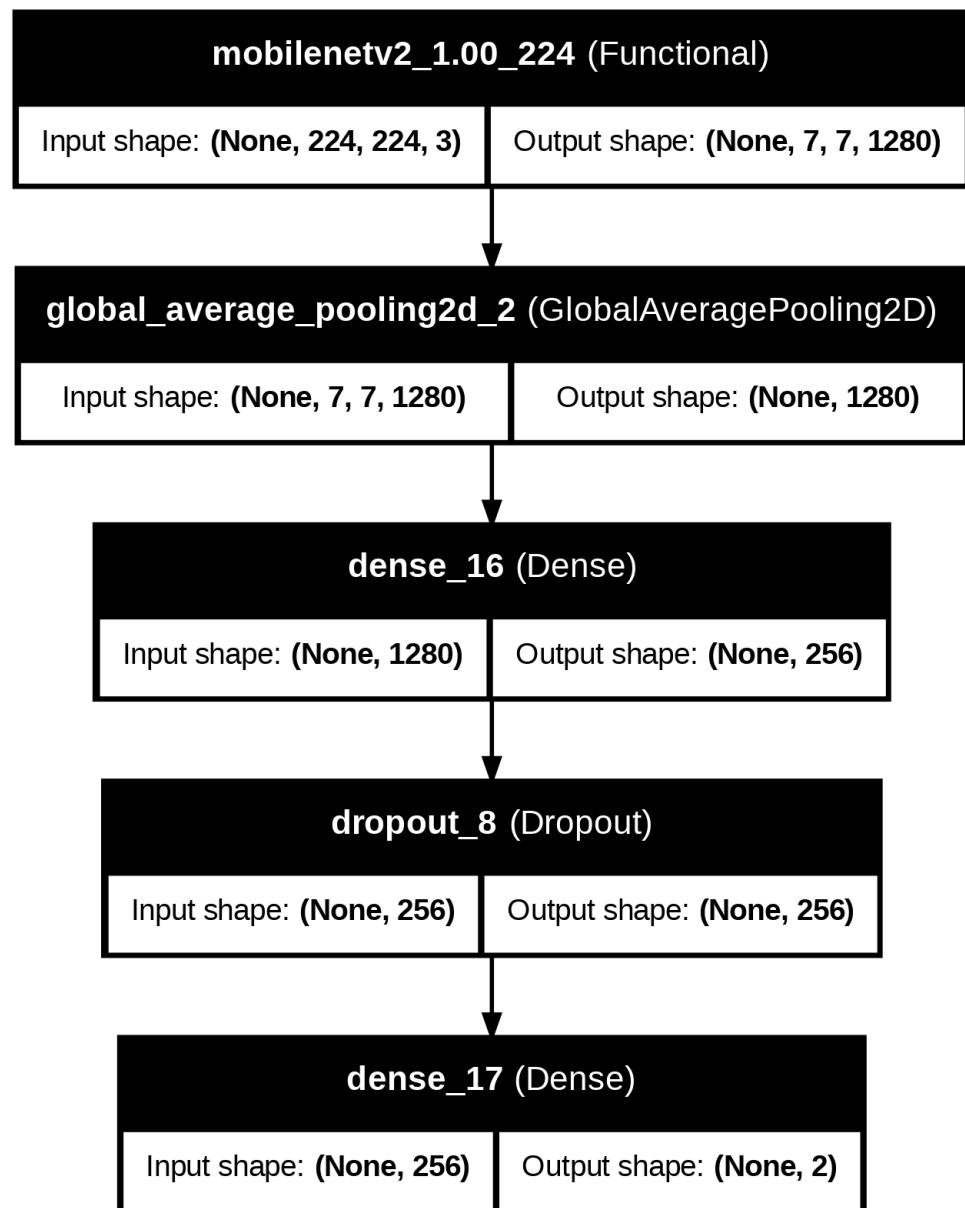
Para o desenvolvimento e avaliação dos modelos, o conjunto de dados foi dividido em três partes: treino (70%), teste (15%) e validação (15%). Essa divisão permite que o modelo seja treinado em uma porção substancial dos dados e posteriormente avaliado em dados desconhecidos, garantindo uma análise robusta do desempenho. Foram utilizados dois modelos de rede neural: uma CNN baseada na arquitetura *MobileNetV2* e a rede VGG16 com camadas adicionais, conforme ilustrado nas Figuras 2 e 3. O modelo VGG16 foi configurado com pesos pré-treinados no *ImageNet* e a última camada totalmente conectada foi removida para incluir camadas personalizadas para a nova tarefa de classificação. Esse modelo inclui uma camada densa com 512 neurônios e ativação *ReLU*, seguida por uma camada de *dropout* com taxa de 50%, que desativa aleatoriamente metade dos neurônios durante o

treinamento para prevenir *overfitting*, e uma camada de saída com ativação *softmax*, com 2 neurônios representando as classes (machos e fêmeas do *Aedes aegypti*).

A arquitetura *MobileNetV2* também foi configurada com pesos do *ImageNet* e as camadas convolucionais foram congeladas para preservar os parâmetros pré-treinados. As camadas adicionais incluem uma camada de *GlobalAveragePooling2D*, que reduz as dimensões das *features* extraídas para uma média global, seguida por uma camada densa com 256 neurônios e ativação *ReLU*, e uma camada de *dropout* com taxa de 50%. A camada de saída possui 2 neurônios e uma função de ativação *softmax*, possibilitando a classificação das imagens. Ambos os modelos foram otimizados com o otimizador Adam, que ajusta os pesos de forma eficiente, com uma taxa de aprendizado de 0.001 para o *VGG16* e 0.0001 para a *MobileNetV2*, permitindo um ajuste cuidadoso dos parâmetros.

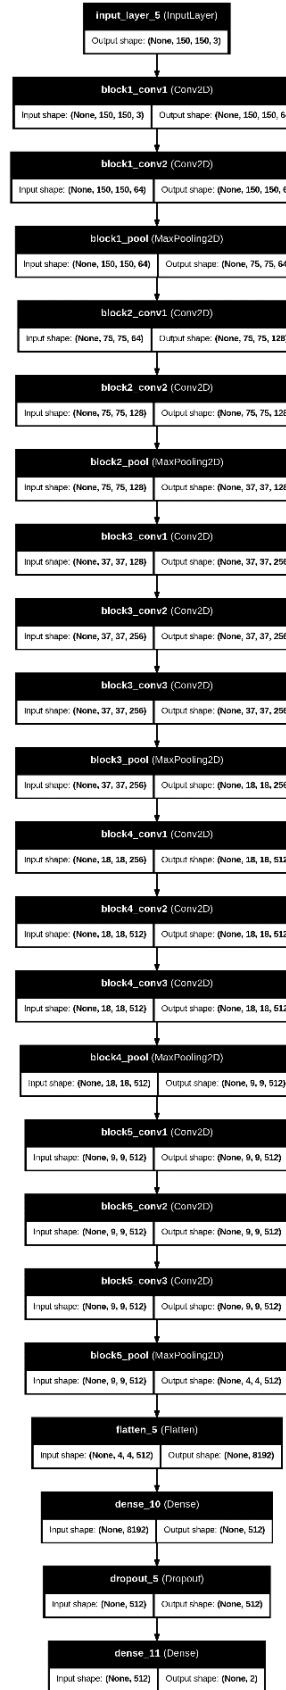
Técnicas de aumento de dados (*Data Augmentation*) foram aplicadas ao conjunto de treino para ampliar a diversidade das amostras e melhorar a capacidade de generalização dos modelos. Essas técnicas incluíram o redimensionamento das imagens para os tamanhos de entrada (150x150 para *VGG16* e 224x224 para *MobileNetV2*), normalização dos pixels para valores entre 0 e 1, rotações aleatórias de até 40 graus, deslocamentos horizontais e verticais de até 20%, cisalhamento, zoom, inversões horizontal e vertical, e ajustes de brilho entre 80% e 120% do valor original. Para evitar o sobreajuste, *callbacks* como *Early Stopping* e *ReduceLROnPlateau* foram implementados. O *Early Stopping* interrompe o treinamento se a perda no conjunto de validação não melhorar após 10 épocas consecutivas, restaurando os melhores pesos do modelo, enquanto o *ReduceLROnPlateau* reduz a taxa de aprendizado em 50% se a perda não melhorar após 5 épocas. O treinamento foi estruturado com lotes de 32 imagens, e o modelo foi treinado por até 30 épocas, permitindo uma análise completa da capacidade de classificação de ambos os modelos.

Figura 2 – Arquitetura do CNN



Fonte – Própria do autor.

Figura 3 – Arquitetura do VGG16



Fonte: Própria do autor

## 3.4 Avaliação

A avaliação dos modelos CNN e VGG16 utilizando métricas diversas revelou diferenças significativas em sua capacidade de classificação, apontando a CNN como o modelo mais eficaz para a tarefa proposta. A acurácia, que representa a proporção de previsões corretas em relação ao total de amostras, atingiu 93% para a CNN e 89% para a VGG16, destacando uma vantagem do modelo CNN em termos de precisão geral.

A precisão (precision) é especialmente relevante ao considerar o impacto de falsos positivos, ou seja, a probabilidade de que uma amostra prevista como uma classe específica seja realmente pertencente a essa classe. No caso da CNN, a precisão foi de 0.92 para a classe “fêmea” e 0.94 para “macho”, enquanto no VGG16 esses valores foram de 0.90 para “fêmea” e 0.88 para “macho”. Esses valores indicam que a CNN é ligeiramente mais confiável ao prever a classe correta, especialmente na classificação de machos.

O recall, que reflete a capacidade do modelo de identificar corretamente as amostras positivas para cada classe, apresentou resultados de 0.94 para “fêmea” e 0.91 para “macho” no modelo CNN. No VGG16, o recall foi de 0.87 para “fêmea” e 0.90 para “macho”. A CNN demonstra uma maior sensibilidade ao identificar ambas as classes, especialmente a classe “fêmea”, o que é essencial no contexto da pesquisa, pois a identificação precisa da fêmea do *Aedes aegypti* é crucial para o controle do vetor de doenças.

O F1-score, uma média harmônica entre precisão e recall, foi de 0.93 para ambas as classes na CNN, indicando um bom equilíbrio entre precisão e sensibilidade. Na VGG16, o F1-score foi de 0.89 para ambas as classes, refletindo um desempenho mais limitado na detecção precisa e consistente das classes. Esse equilíbrio entre precisão e recall na CNN a torna mais confiável para tarefas onde ambos os valores são críticos.

A análise da matriz de confusão evidencia a precisão e os erros de cada modelo em relação a cada classe. A CNN apresentou 131 acertos e 19 erros para a classe “fêmea” e 135 acertos e 15 erros para a classe “macho”, enquanto o VGG16 teve 141

acertos e 9 erros para “fêmea” e 137 acertos e 13 erros para “macho”. A CNN apresenta uma distribuição mais equilibrada de erros e acertos entre as classes, reforçando sua capacidade de generalização.

Por fim, a análise da curva ROC e do valor AUC para cada classe confirmou a superioridade da CNN em relação ao VGG16. A área sob a curva ROC foi de 0.96 para ambas as classes na CNN e 0.97 no VGG16, o que indica que ambos os modelos são altamente eficazes em discriminar entre as classes, mas com uma leve vantagem para a VGG16. Entretanto, considerando todas as métricas, a CNN apresentou um desempenho mais robusto e consistente ao longo das fases de teste e validação.

Em resumo, o modelo CNN demonstrou-se superior ao VGG16 na tarefa de classificação entre machos e fêmeas do *Aedes aegypti*, especialmente em métricas de precisão, recall e F1-score, e foi mais confiável na identificação correta das classes em condições variadas. Esse desempenho reforça a aplicabilidade da CNN para o objetivo da pesquisa, com potencial para ser implementado em sistemas de monitoramento e controle epidemiológico que demandam alta precisão e sensibilidade na identificação do vetor da dengue.

Na próxima seção, serão apresentados e discutidos os resultados obtidos com os modelos de redes neurais testados nesta pesquisa. A análise detalhada das métricas de desempenho, incluindo acurácia, precisão, recall, F1-score, matriz de confusão e curva ROC, fornecerá uma compreensão mais profunda sobre a eficácia dos modelos CNN e VGG16 na classificação de machos e fêmeas do *Aedes aegypti*. Além disso, serão exploradas as implicações desses resultados no contexto do controle do vetor da dengue, ressaltando o potencial de cada modelo para contribuir com ações de monitoramento e controle epidemiológico. Com essa avaliação, buscaremos identificar o modelo mais adequado e examinar as possíveis melhorias e ajustes que podem ser implementados para futuras aplicações.

# Capítulo 4

## Resultados

A avaliação detalhada dos modelos *CNN* e *VGG16* para a identificação do mosquito *Aedes aegypti*, vetor da dengue, apresenta resultados distintos conforme as métricas de desempenho ilustradas na Tabela 1. Ambas as redes neurais alcançaram resultados expressivos, com o modelo *CNN* destacando-se pela sua maior acurácia e equilíbrio nas métricas de precisão, *recall* e *F1-Score*. A *CNN* obteve uma acurácia de 93% para ambas as classes, enquanto o *VGG16* apresentou uma acurácia ligeiramente inferior, de 89%. Esse diferencial demonstra que a *CNN* possui uma capacidade superior de generalização e consistência na classificação de imagens, sendo mais eficaz para identificar corretamente machos e fêmeas do mosquito.

Tabela 1 – Avaliação das métricas

Modelo	Classe	Acurácia	Precisão	F1-Score	Recall
VGG16	aee-fêmea	0,89	0,90	0,89	0,87
VGG16	aee-macho	0,89	0,88	0,89	0,90
CNN	aee-fêmea	0,93	0,92	0,93	0,94
CNN	aee-macho	0,93	0,94	0,93	0,91

Fonte: Própria do autor

A precisão do modelo *CNN* para a classe fêmea foi de 0.92 e para macho foi de 0.94, valores superiores aos obtidos pelo *VGG16*, que foram de 0.90 para fêmea e 0.88 para macho. Esses valores de precisão indicam que a *CNN* é mais confiável ao prever a classe correta, especialmente ao identificar a classe macho com maior precisão. O *recall*, por sua vez, reflete a capacidade do modelo de detectar verdadeiros positivos para cada classe. A *CNN* obteve um *recall* de 0.94 para a classe fêmea e 0.91 para macho, enquanto o *VGG16* alcançou 0.87 para fêmea e 0.90 para

macho. Esses resultados confirmam que a *CNN* é mais sensível na identificação da classe fêmea, o que é crucial para o controle do vetor, já que as fêmeas são as responsáveis pela transmissão da dengue.

O *F1-Score*, que equilibra precisão e *recall*, foi de 0.93 para ambas as classes no modelo *CNN*, indicando um bom balanceamento entre as duas métricas e destacando o modelo como mais robusto e confiável. O *VGG16*, com *F1-Score* de 0.89 para ambas as classes, apresentou um desempenho inferior em termos de equilíbrio entre precisão e *recall*. Esse valor de *F1-Score* da *CNN* reforça sua eficácia na tarefa de classificação, proporcionando resultados consistentes e minimizando a possibilidade de erros que poderiam comprometer a identificação da fêmea do mosquito.

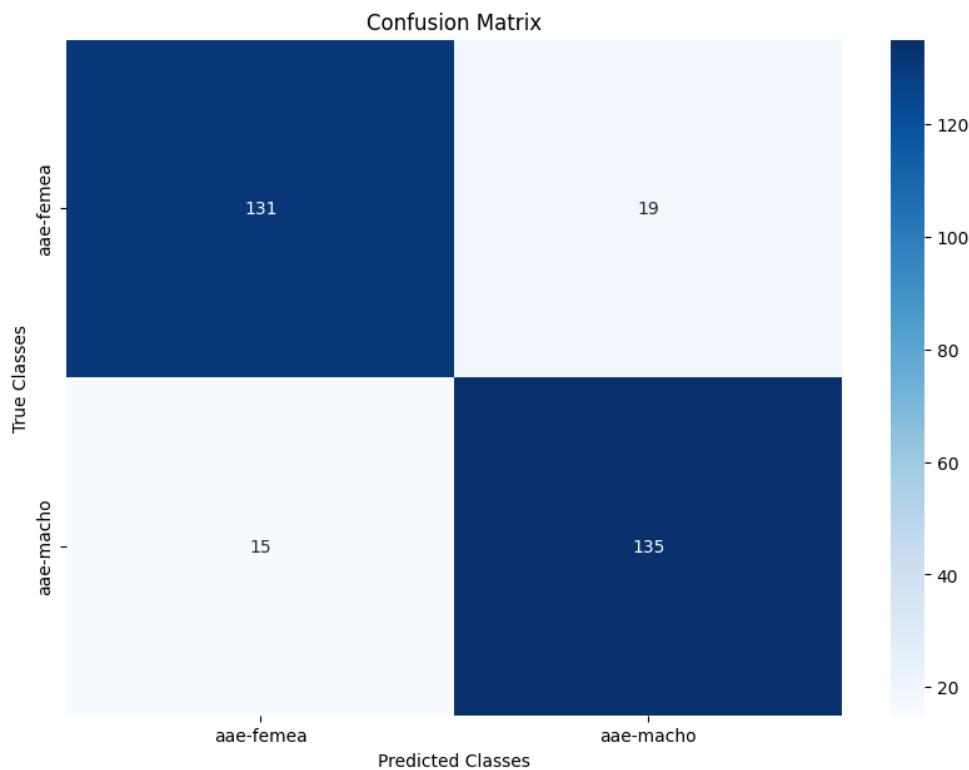
Considerando esses resultados, o modelo *CNN* foi escolhido para a tarefa de classificação da fêmea do mosquito *Aedes aegypti*, especialmente por sua maior acurácia e desempenho superior nas métricas de precisão e *recall* para ambas as classes. A análise dos resultados obtidos evidencia que a *CNN* não apenas é mais precisa, mas também é mais sensível ao identificar a classe de interesse (fêmea), tornando-a a opção mais adequada para implementação em sistemas de monitoramento e controle epidemiológico voltados ao combate da dengue. A escolha do modelo *CNN* se justifica pela sua habilidade em equilibrar precisão e sensibilidade, garantindo uma detecção mais confiável e eficiente da fêmea do mosquito vetor, o que é fundamental para reduzir a incidência da doença.

## 4.1 Desempenho do modelo *VGG16*

O *VGG16*, conhecido por sua arquitetura profunda e capacidade de extração de características complexas, alcançou uma acurácia de 89%. Essa acurácia, embora elevada, é inferior à obtida pelo modelo *CNN*, indicando que o *VGG16* teve maior dificuldade em capturar as nuances entre as classes aae-fêmea e aae-macho. A precisão do modelo para a classe aae-fêmea foi de 0.90 e para aae-macho foi de 0.88, sugerindo que o *VGG16* apresentou uma taxa de erros ligeiramente maior ao classificar machos, o que pode ser atribuído a uma menor especialização nas características que distinguem as classes. A Figura 4 ilustra os erros e acertos de

classificação, permitindo uma visão clara dos desafios enfrentados pelo modelo ao classificar as duas classes.

Figura 4 – Matriz de Confusão do VGG16

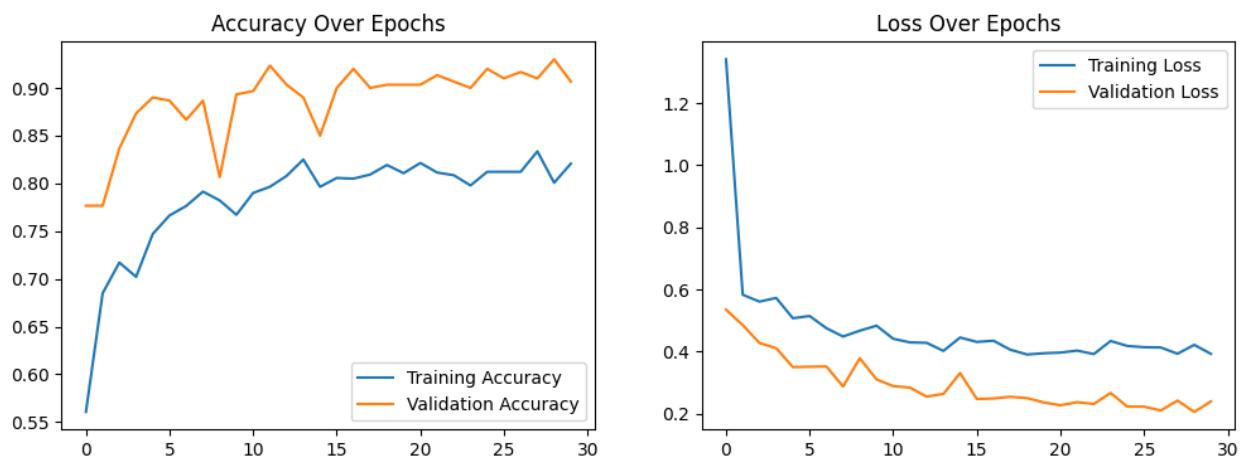


Fonte: Própria do autor

No quesito recall, o VGG 16 obteve 0.87 para aae-fêmea e 0.90 para aae-macho. Esses valores mostram que o modelo conseguiu identificar melhor a classe aae-macho do que aae-fêmea, o que pode representar uma limitação, considerando que a identificação da fêmea do *Aedes aegypti* é mais relevante para o controle do vetor da dengue. O *F1-Score*, que é uma média harmônica entre precisão e *recall*, foi de 0.89 para ambas as classes, refletindo um desempenho equilibrado, mas menos eficaz quanto a CNN. A Figura 5 fornece uma análise sobre a estabilidade do modelo ao longo do treinamento, mostrando uma tendência de convergência, embora com uma acurácia final menor.

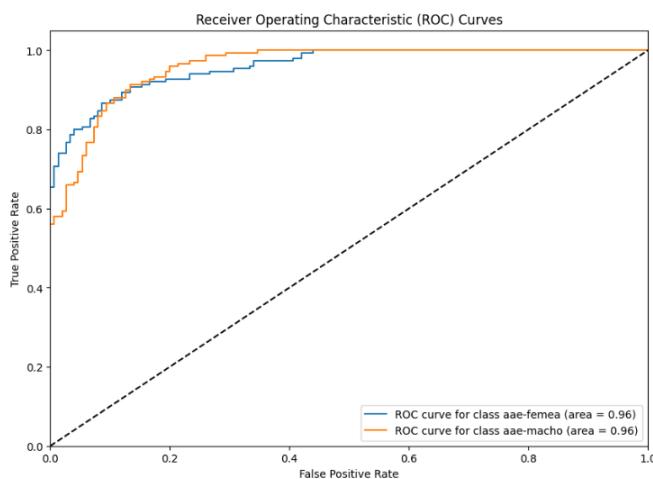
*Na análise da curva ROC do VGG16, a área sob a curva revelou uma Area under the curve (AUC) de 0.97 para ambas as classes, indicando uma boa capacidade de discriminação entre aae-fêmea e aae-macho, como ilustra a Figura 6 para uma visualização mais clara do desempenho do modelo. Esse alto valor de AUC sugere que o modelo é competente em classificar as classes em uma ampla gama de limiares, o que pode ser útil em aplicações onde a sensibilidade pode ser ajustada conforme a necessidade.*

Figura 5 – Gráfico de Acurácia e Perda do modelo VGG16



Fonte: Própria do autor

Figura 6 – Curva Roc do modelo VGG16

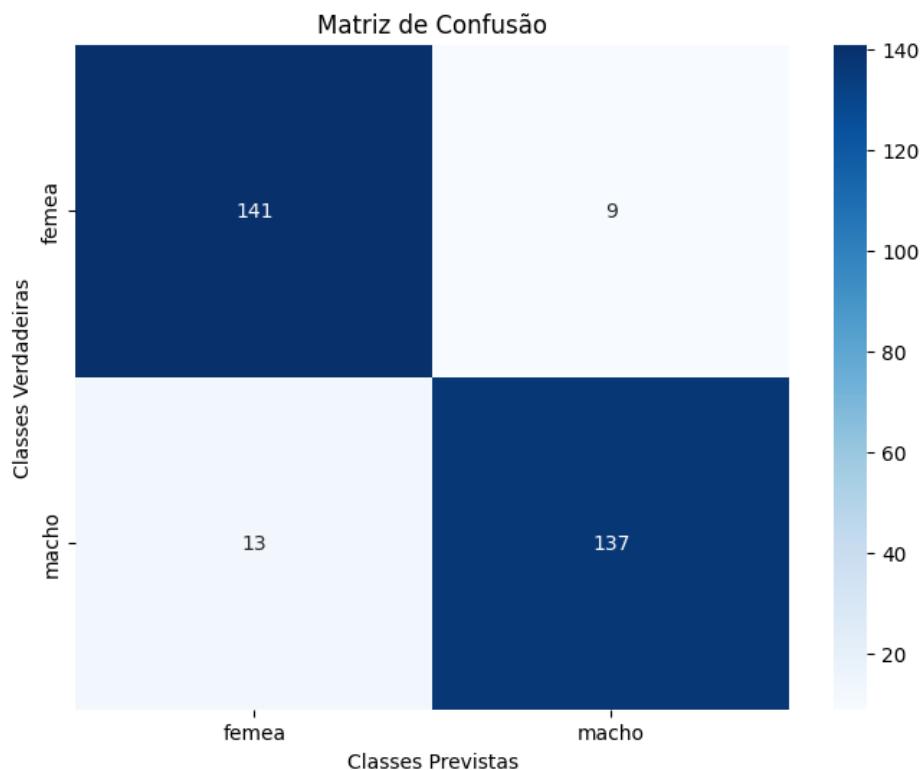


Fonte: Própria do autor

## 4.2 Desempenho do Modelo CNN

O modelo CNN, baseado na arquitetura *MobileNetV2*, obteve uma acurácia superior de 93%, destacando-se como a opção mais eficiente para a tarefa de classificação do *Aedes aegypti*. Com uma precisão de 0.92 para a classe fêmea (a classe alvo) e 0.94 para macho, o modelo mostrou-se altamente confiável ao prever ambas as classes. Esse resultado sugere que a CNN possui uma capacidade superior de aprender padrões relevantes para a diferenciação entre as classes, o que contribui para uma maior acurácia geral. A Figura 7 revela uma distribuição equilibrada de acertos e erros, evidenciando que o modelo é eficaz em minimizar erros de classificação, tanto para fêmea quanto para macho.

Figura 7 – Matriz de confusão do CNN

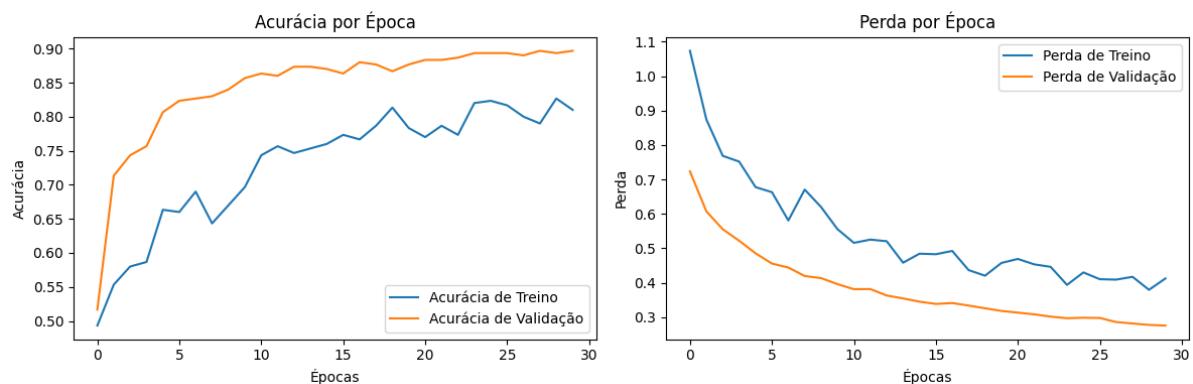


Fonte: Própria do autor.

Em termos de *recall*, a CNN demonstrou valores de 0.94 para fêmea e 0.91 para macho, reforçando sua capacidade de detectar verdadeiros positivos, especialmente para a classe alvo. Esse alto valor de recall para a classe alvo é crucial, pois identifica precisamente os mosquitos que representam um risco

epidemiológico. O *F1-Score* da CNN, de 0.93 para ambas as classes, indica um equilíbrio excelente entre precisão e *recall*, tornando o modelo uma ferramenta confiável para a tarefa proposta. A Figura 8 mostra que o modelo atingiu uma convergência estável durante o treinamento, com uma perda decrescente, evidenciando a eficácia do modelo ao longo das épocas.

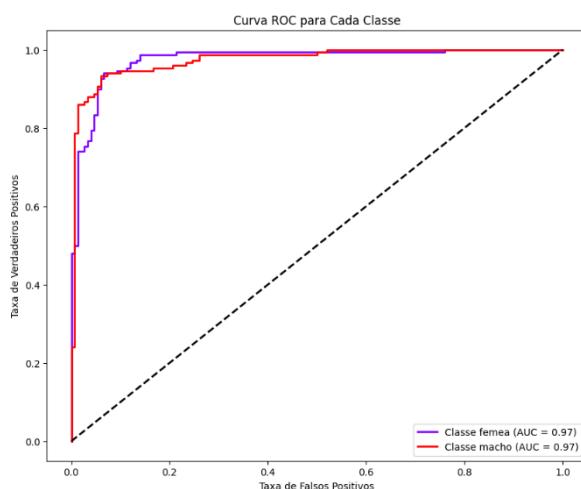
Figura 8 – Gráficos de Acurácia e Perda do modelo CNN



Fonte: Própria do autor.

A análise da curva *ROC* para o modelo CNN revelou uma *AUC* de 0.96 para ambas as classes, ligeiramente inferior ao VGG16. Embora o valor de *AUC* seja menor, o desempenho geral do modelo CNN, incluindo acurácia, precisão, *recall* e *F1-Score*, o torna uma opção mais robusta e confiável. A Figura 9 permitiu uma avaliação mais direta com a curva *ROC* do VGG16 e reforçar a discriminação eficiente entre as classes.

Figura 9 - Curva ROC do modelo CNN



Fonte: Própria do autor

## 4.3 Análise detalhada dos modelos

Ao analisar os resultados dos dois modelos, é evidente que a *CNN* supera o *VGG16* em quase todas as métricas, exceto na *AUC*, onde o *VGG16* apresentou um valor ligeiramente superior de 0.97 em paralelo com 0.96 da *CNN*. No entanto, a acurácia de 93% da *CNN* é consideravelmente superior à acurácia de 89% do *VGG16*, indicando que a *CNN* é mais eficaz na classificação precisa de machos e fêmeas do mosquito *Aedes aegypti*. Além disso, o *F1-Score* superior da *CNN* (0.93 contra 0.89 do *VGG16*) demonstra que o modelo *CNN* tem uma performance mais equilibrada entre precisão e o *recall*, reduzindo erros de classificação em ambas as classes.

A precisão e o *recall* da *CNN* também são superiores para ambas as classes, sugerindo que o modelo é mais confiável tanto na identificação da classe alvo quanto na aee-macho. Esse desempenho é especialmente relevante no contexto epidemiológico, pois a identificação precisa da fêmea é crucial para a prevenção da dengue. Embora o *VGG16* tenha mostrado uma capacidade de discriminação ligeiramente superior em termos de *AUC*, essa métrica isolada não compensa a diferença de acurácia e *F1-Score* entre os modelos.

Com base na análise detalhada das métricas, o modelo *CNN* foi escolhido como o modelo mais adequado para a tarefa de identificação da fêmea do mosquito *Aedes aegypti*. A *CNN* oferece uma acurácia maior, melhor equilíbrio entre precisão e *recall* e uma classificação mais confiável em ambas as classes. A ligeira vantagem do *VGG16* na métrica *AUC* não foi suficiente para superar as vantagens gerais da *CNN*, que demonstrou maior robustez e eficácia para esta aplicação. Essa escolha é respaldada pelas métricas de desempenho, bem como pela análise visual das matrizes de confusão e curvas *ROC*, que reforçam a capacidade da *CNN* de generalizar melhor e classificar com maior precisão o vetor da dengue.

Na próxima sessão, apresentaremos o Capítulo 5, onde serão discutidas as conclusões finais desta pesquisa. Nesse capítulo, sintetizaremos os principais achados e implicações dos resultados obtidos com os modelos *CNN* e *VGG16*, avaliando o impacto de cada métrica no desempenho e na eficácia da classificação entre machos e fêmeas do *Aedes aegypti*. Além disso, exploraremos as contribuições

deste trabalho para o campo de identificação de vetores da dengue, destacando as limitações encontradas e sugerindo direções para futuras pesquisas que possam aprimorar ainda mais a precisão e a aplicabilidade dos modelos propostos em contextos epidemiológicos e de controle de doenças.

# Capítulo 5

## Considerações Finais

Este trabalho aborda o desafio de identificar de forma automática a fêmea do mosquito *Aedes aegypti*, vetor principal da dengue, utilizando CNNs em imagens de alta resolução obtidas por microscopia digital. A resolução desse problema é fundamental para melhorar o controle vetorial da dengue, uma vez que a identificação precisa da fêmea do *Aedes aegypti* é crucial para ações preventivas de saúde pública. Os resultados desta pesquisa enfatizam que as técnicas de aprendizado de máquina, aplicadas a um conjunto de dados de imagens adequadamente processadas, podem contribuir de forma expressiva para a identificação e controle de vetores.

Cada um dos objetivos específicos estabelecidos foi atendido de maneira a contribuir diretamente para o objetivo geral de desenvolver um modelo de identificação robusto e preciso. O primeiro objetivo específico, relacionado ao pré-processamento das imagens coletadas, foi cumprido com a aplicação de técnicas de normalização, redimensionamento e *data augmentation*, o que possibilitou uma otimização na extração de características dos mosquitos. Esse pré-processamento garantiu que as imagens utilizadas no treinamento das redes apresentassem uma diversidade e uma qualidade adequadas para melhorar a generalização e a acurácia do modelo.

O segundo objetivo, que consistia em treinar CNNs utilizando essas imagens processadas, foi realizado com sucesso. As arquiteturas *MobileNetV2* e *VGG16* foram treinadas e analisadas em termos de desempenho, proporcionando uma análise robusta de cada modelo. O terceiro objetivo, que envolvia a avaliação das redes usando métricas de desempenho como acurácia, precisão, *recall*, *F1-score*, matriz de confusão e curva *ROC*, revelou que o modelo *MobileNetV2* apresentou uma acurácia final de 93%, enquanto o *VGG16* ficou em 89%. Além de sua acurácia superior, a *MobileNetV2* mostrou maior equilíbrio em todas as métricas, destacando-se como a arquitetura mais eficaz para a identificação precisa do vetor feminino.

Por fim, o último objetivo de selecionar o modelo com as melhores métricas foi atingido com a escolha da *MobileNetV2*, que demonstrou maior robustez e capacidade de generalização para identificar a fêmea do mosquito *Aedes aegypti*. Esse resultado indica que, além da alta acurácia, o modelo tem potencial de ser utilizado como uma ferramenta confiável para o monitoramento e controle da dengue.

Analizando os estudos anteriores, como o de Motta (2019), que também utilizou CNNs mas enfrentou limitações em condições variadas de iluminação, este trabalho obteve resultados superiores, tanto na acurácia quanto no equilíbrio entre as métricas. A abordagem utilizada nesta pesquisa permitiu um desempenho mais robusto em ambientes controlados e, potencialmente, em condições mais variáveis, sugerindo que a *MobileNetV2* é uma escolha promissora para identificação em campo.

No entanto, algumas limitações foram identificadas, como a necessidade de maior variação nas condições de captura das imagens para assegurar a adaptabilidade do modelo a diferentes ambientes. A ausência de imagens capturadas em contextos menos controlados, com variações de ângulo e iluminação, pode limitar a aplicabilidade do modelo em situações de campo. Como trabalho futuro, recomenda-se a exploração de outras técnicas de aprendizado de máquina, como redes neurais profundas mais avançadas, bem como a adaptação do modelo desenvolvido para execução em dispositivos de borda, permitindo a vigilância entomológica em tempo real. A aplicação de modelos em dispositivos de borda possibilitaria o monitoramento contínuo e a intervenção mais ágil em áreas de risco, ampliando o impacto da solução no controle epidemiológico da dengue e na saúde pública.

# Referências

G1. Brasil supera a marca de 2 milhões de casos de dengue em 2024 e mortes passam de 680. Disponível em: <https://g1.globo.com/saude/dengue/noticia/2024/03/22/brasil-supera-a-marcade-2-milhoes-de-casos-de-dengue.ghtml>. Acesso em: 11 nov. 2024.

Ministério da Saúde. Aedes aegypti. Disponível em: <https://www.gov.br/saude/pt-br/assuntos/saude-de-a-a-z/a/aedes-aegypti>. Acesso em: 11 nov. 2024.

Fiocruz. Aedes aegypti: série de vídeos alerta para a importância da prevenção. Disponível em: <https://portal.fiocruz.br/noticia/2024/01/aedes-aegypti-serie-de-videos-alerta-para-importancia-da-prevencao>. Acesso em: 11 nov. 2024.

Mariano, D. (2021, April 25). Métricas de avaliação em machine learning. diegomariano.com. <https://diegomariano.com/metricas-de-avaliacao-em-machine-learning/>

Torgo, L., & Ribeiro, R. (2009). Precision and Recall for Regression. In Discovery Science (pp. 332–346). Springer Berlin Heidelberg.

Zhang, D., Wang, J., & Zhao, X. (2015). Estimating the Uncertainty of Average F1 Scores. ACM. <http://dx.doi.org/10.1145/2808194.2809488>

Nakas, C. (2023). ROC Analysis for Classification and Prediction in Practice. CRC Press.

## MATRIX DE CONFUSÃO (LIANG, 2022)

LIANG, Jingsai. Confusion matrix: Machine learning. POGIL Activity Clearinghouse, v. 3, n. 4, 2022.

CASTEL, L. D. Sistema Embarcado Classificador de Mosquitos Aedes aegypti por Modelo Inteligente. 2023.

GARCIA, P. Aquisição de imagens digitais e identificação dos ovos do mosquito Aedes Aegypti baseado em um modelo de aprendizado profundo. 2019.

JÚNIOR, G. C. Reconhecimento de espécies de mosquitos por meio de métodos computacionais inteligentes baseados em aprendizagem profunda. 2022.

MITTELMANN, M.; APPLICADA, D. S.-R. DE I.; 2017, UNDEFINED. Previsão de Casos de Dengue em Guarulhos com Redes Neurais Artificiais Multicamadas e Recorrentes. [seer.uscs.edu.br](http://seer.uscs.edu.br), [s.d.].

MOTTA, D. Otimização na classificação automática de mosquitos adultos: uma investigação com redes neurais convolucionais (CNN). 2019.

VINICIO RODRIGUES DE LIMA. **Inteligência artificial para classificação de espécies de culicídeos baseada em morfometria de asa.** [s.l: s.n.]. Disponível em: <<https://www.teses.usp.br/teses/disponiveis/5/5179/tde-16042024-161016/en.php>>. Acesso em: 10 nov. 2024.